유호원 YU HOWON

mail : yoohowon@gmail.com
github: https://github.com/HowardHowonYu
blog : https://howardhowonyu.github.io/

EDUCATION

- **패스트 캠퍼스**
  데이터 사이언스 스쿨 — 2020년 01월 – 2020년 05월
- **Tsinghua Univ. (청화대학교 – 清華大學)**
  Journalism and Communication 학사 — 2009년 09월 – 2015년 07월

PROJECTS

Machine Learning Project

- **회귀분석** – Craiglist(미국의 중고 매물, 부동산, 구인 등을 다루는 커뮤니티)의 중고차 매물 데이터를 활용한 가격 예측 프로젝트. 약 51만 건의 데이터. 허위 및 광고성 매물 데이터에 존재하는 이상치 제거를 위해, 미국 정부 기관에서 관리하는 차량 이력 데이터베이스를 활용. 허위 매물 제거 및 차량 주행거리, 연식에 대해 신뢰도 높은 데이터 획득. 중고차 가격이 급격히 떨어지는 지점에 대한 가설 검증. 국내 중고차 시장 주행거리 5만km가 기점, 가설을 검증 결과 미국 중고차 시장에서도 약 3만 마일(4만8천km)을 기점으로 가격이 급격히 떨어지는 모습을 확인.
- **교통 표지판 분류** – keras를 이용한 표지판 분류 프로젝트, CNN 기법을 활용. 정부 기관에서 pdf 형태로 배포하는 표지판 이미지를 가공, keras를 이용해 Image augmentation 진행. 실제 도로에서 획득할수 있는 형태의 이미지로 전환하여 프로젝트 진행.
- **카카오 아레나 대회** – 멜론 플레이리스트 곡 목록 및 태그 예측.

Works

- **Job Hunter 프로젝트** – Slack에서 여러 구인 사이트의 공고를 한번에 볼수있도록 하는 app 제작 프로젝트. 사람인, 잡코리아, 로켓펀치등의 웹사이트를 크롤링, Scrapy Framework을 활용, AWS EC2에 Crontab을 활용하여 주기적인 크롤링 실행. Flask를 이용하여 Slack app의 server를 제작.
- **EDA 프로젝트** – Instacart 신선 식품 구매 데이터 탐색 및 분석 프로젝트.

EXPERIENCE

2018년 03월 – 2019년 02월

- **블릿츠 : 영상 컨텐츠, 광고, 의류 제작 –** 사업 초기 자금 투자 유치 업무 진행, 사업 기획 및 콘텐츠 제작 Workflow 설계. 브랜디드 콘텐츠, 오리지널 콘텐츠 제작 총괄, BPH 화장품 “하이드로 컴플렉스 수딩 아쿠아젤” SNS 바이럴 콘텐츠, 뮤직 드라마,15초 내외의 마이크로 필름 제작 담당.

2016년 09월 – 2017년 11월

- **더저스트폴미스핏츠 : 소셜미디어 JustForMe개발 –** “JustForMe“ 앱 중화권 마케팅 담당 : 소셜미디어 콘텐츠 마케팅 플랜 현지화를 위한 번역 및 감수 진행. 중화권 DAU 분기별 약 200% 성장, 중문(간체, 번체) 버전 번역 및 디자인 담당, 번체 사용 지역(대만, 홍콩및 동남아)과 간체 사용 지역(중국 대륙)을 이원화하여 각 특성에 맞는 기능 설계, 정부 지원 사업 (사무 공간 지원, 마케팅 자금 지원) 커뮤니케이션 담당, Adobe XD, Illustrartor, Sketch등을 활용한 Artwork 제작

2014년 08월 – 2015년 03월

- **박중미래(博众未来) – 영화 프로덕션 인턴** : 시나리오 현지화 기획팀 인턴, 영화 ”보톡스” 시나리오 현지화를 위한 중국 관객 및 영화 관계자 대상 앙케이트 진행, 데이터 분석, 시나리오 번역 업무 진행.

2009년 12월 – 2010년 06월

- **International internship program AIESEC, OGX(out going exchange) teamleader** : 청화대 AIESEC 회원 대상 해외 실습 파견 업무 진행, 4개국, 5개 대학과 교류추진, 2010 년 1 월 AIESEC 동북지역대학연합회의 조직, 3개국가의 60명이상의 학생들 참가.

SKILLS

- **Programming Language :** Python, HTML, CSS, JavaScript
- **Framework & Packages :** Tensorflow, Scikit Learn, Pandas, Numpy
- **Tools :** Adobe Premier, After effect, Illustrator, Sketch
- **외국어** : 중국어 (상급)

EXPERIENCE

- **경력 상세 설명**

저는 2번의 창업에 공동창업자로 참여하며, 고객 니즈에 맞춘 서비스를 기획하고 자체 브랜드를 기획하기 위한 Data 기반 의사결정에 집중해 왔습니다.

고객 피드백 데이터에 기반한 서비스 기획 - 소셜미디어 애플리케이션 "JustForMe" 중화권 Localization

1. 앱 개발 초기 단계부터 데이터 수집을 위해 Google Analytics 를 활용하여 DAU 등의 변화량을 측정하고, 애플리케이션 동작의 각 단계에서 발생하는 Action 등을 수집 및 분석하였습니다. 이 과정에서 한국 유저와는 다른 중화권 유저들만의 고유한 이용 패턴에 대한 인사이트를 추출할 수 있었습니다. 이를 활용하여 지속적인 업데이트를 통해 중화권 유저 맞춤 기능(한문 특화 폰트 지원 등)을 추가하였습니다.

2. 유저 Feedback 을 수집하여, 간체를 사용하는 중국 대륙과, 번체를 사용하는 홍콩, 대만 및 동남아 유저들이 앱상에서 사용하는 특정 단어 Ex) 이메일 주소 = 邮箱账号(간체), 電郵地址(번체) 등의 차이를 찾아내고 이를 서비스에 반영하여 매달 200% 이상의 유저 이용률 증가를 만들어 냈습니다.

3. 온라인 콘텐츠 마케팅 업무도 진행하며, 중화권에 맞춘 애니메이션 영상 제작을 담당하였습니다. 이와 같은 업무들을 통해 중화권 고객들의 전환율의 지속적인 상승과 광고 효율의 재고를 이끌어 냈습니다.

캠페인 이름	게재	입찰 전략	예산	결과	도달	노출	결과당 비용
JustForMe - taiwan	꺼짐	광고 세트 입...	광고 세트 ...	15 모바일 앱 설치	1,954	1,962	₩413 모바일 앱 설...
JustForMe - Korea	꺼짐	광고 세트 입...	광고 세트 ...	1 모바일 앱 설치	153	161	₩1,835 모바일 앱 설...
taiwan - 일기,자신. (7/22~8/21) 남녀	꺼짐	광고 세트 입...	광고 세트 ...	406 모바일 앱 설치	26,840	37,146	₩246 모바일 앱 설...
theJustForMe - taiwan (AD)	꺼짐	광고 세트 입...	광고 세트 ...	1,046 모바일 앱 설치	45,974	75,413	₩215 모바일 앱 설...

- **자기소개서**

[문제 해결 능력]
사업을 진행하며 주인의식을 가지고 업무를 진행해 왔기 때문에 문제에 부딪혔을 때 끝까지 파고들어 해결해 왔습니다.
영상 콘텐츠 회사 투자유치 초반, 성과를 내지 못했었습니다. 이를 극복하기 위해, 동종업계의 사례들과 투자 업체들의 사례를 조사한 결과 소수의 투자 가능한 회사에 집중해야 한다는 결론을 만들었습니다. 각 투자처의 성향에 맞는 프로토타입 콘텐츠를 제작하고 이를 바탕으로 한 사업 기획을 만들었습니다. 결국 (주) 72초 TV에서 투자받을 투자 받을 수 있었습니다. 이처럼 문제를 해결해 나가며 여러 시각에서 바라보는 폭넓은 사고력과 문제 해결을 위해 끝까지 노력하는 집요함을 기를 수 있었습니다.

[끊임없는 학습에 특화된 인재]
데이터를 다루는 사람은 끊임없는 학습이 기본이 되어야 한다고 생각합니다. 저는 중국에서 공부하고 한국에 와서 두 번의 창업을 진행하며, 항상 새로운 지식을 배워야만 하는 상황에 놓였습니다. 그때마다 필요한 지식을 습득하고 빠르게 업무에 적용해왔습니다.

또한, 패스트 캠퍼스 데이터 사이언스 스쿨을 이수하며, 수학 및 통계적인 지식을 많이 습득했습니다. 이는 앞으로 변화하는 새로운 데이터 처리 및 머신러닝 기법에 대한 학습을 빠르고 정확하게 진행할 수 있는 기초가 될 것입니다. 또한, 앞으로 업무에 필요한 역량을 빠르게 습득하는 데 도움이 되리라 생각합니다.

PROJECTS

Machine Learning Project

회귀분석

미국 중고차 가격 예측

Notebook : https://nbviewer.jupyter.org/github/HowardHowonYu/usedcar_regression_project/blob/howard/howard/used_car_regression_final.ipynb

Technical Skills : Python, Scikit-learn, Pandas, Numpy

연구 가설

- 주행거리 5만km 이하일때 차량을 파는것이 가격적으로 유리할 것이다.
- 지역별 가격차이가 있을 것이다.

데이터 출처

- Craigslist(https://craigslist.org) : 중고 매물, 구인 구직, 주택, 자유 주제 토론등을 다루는 커뮤니티 웹사이트
- 미국내 중고차 매물 약 51만 건(업데이트 : 2020년 1월)

Workflow

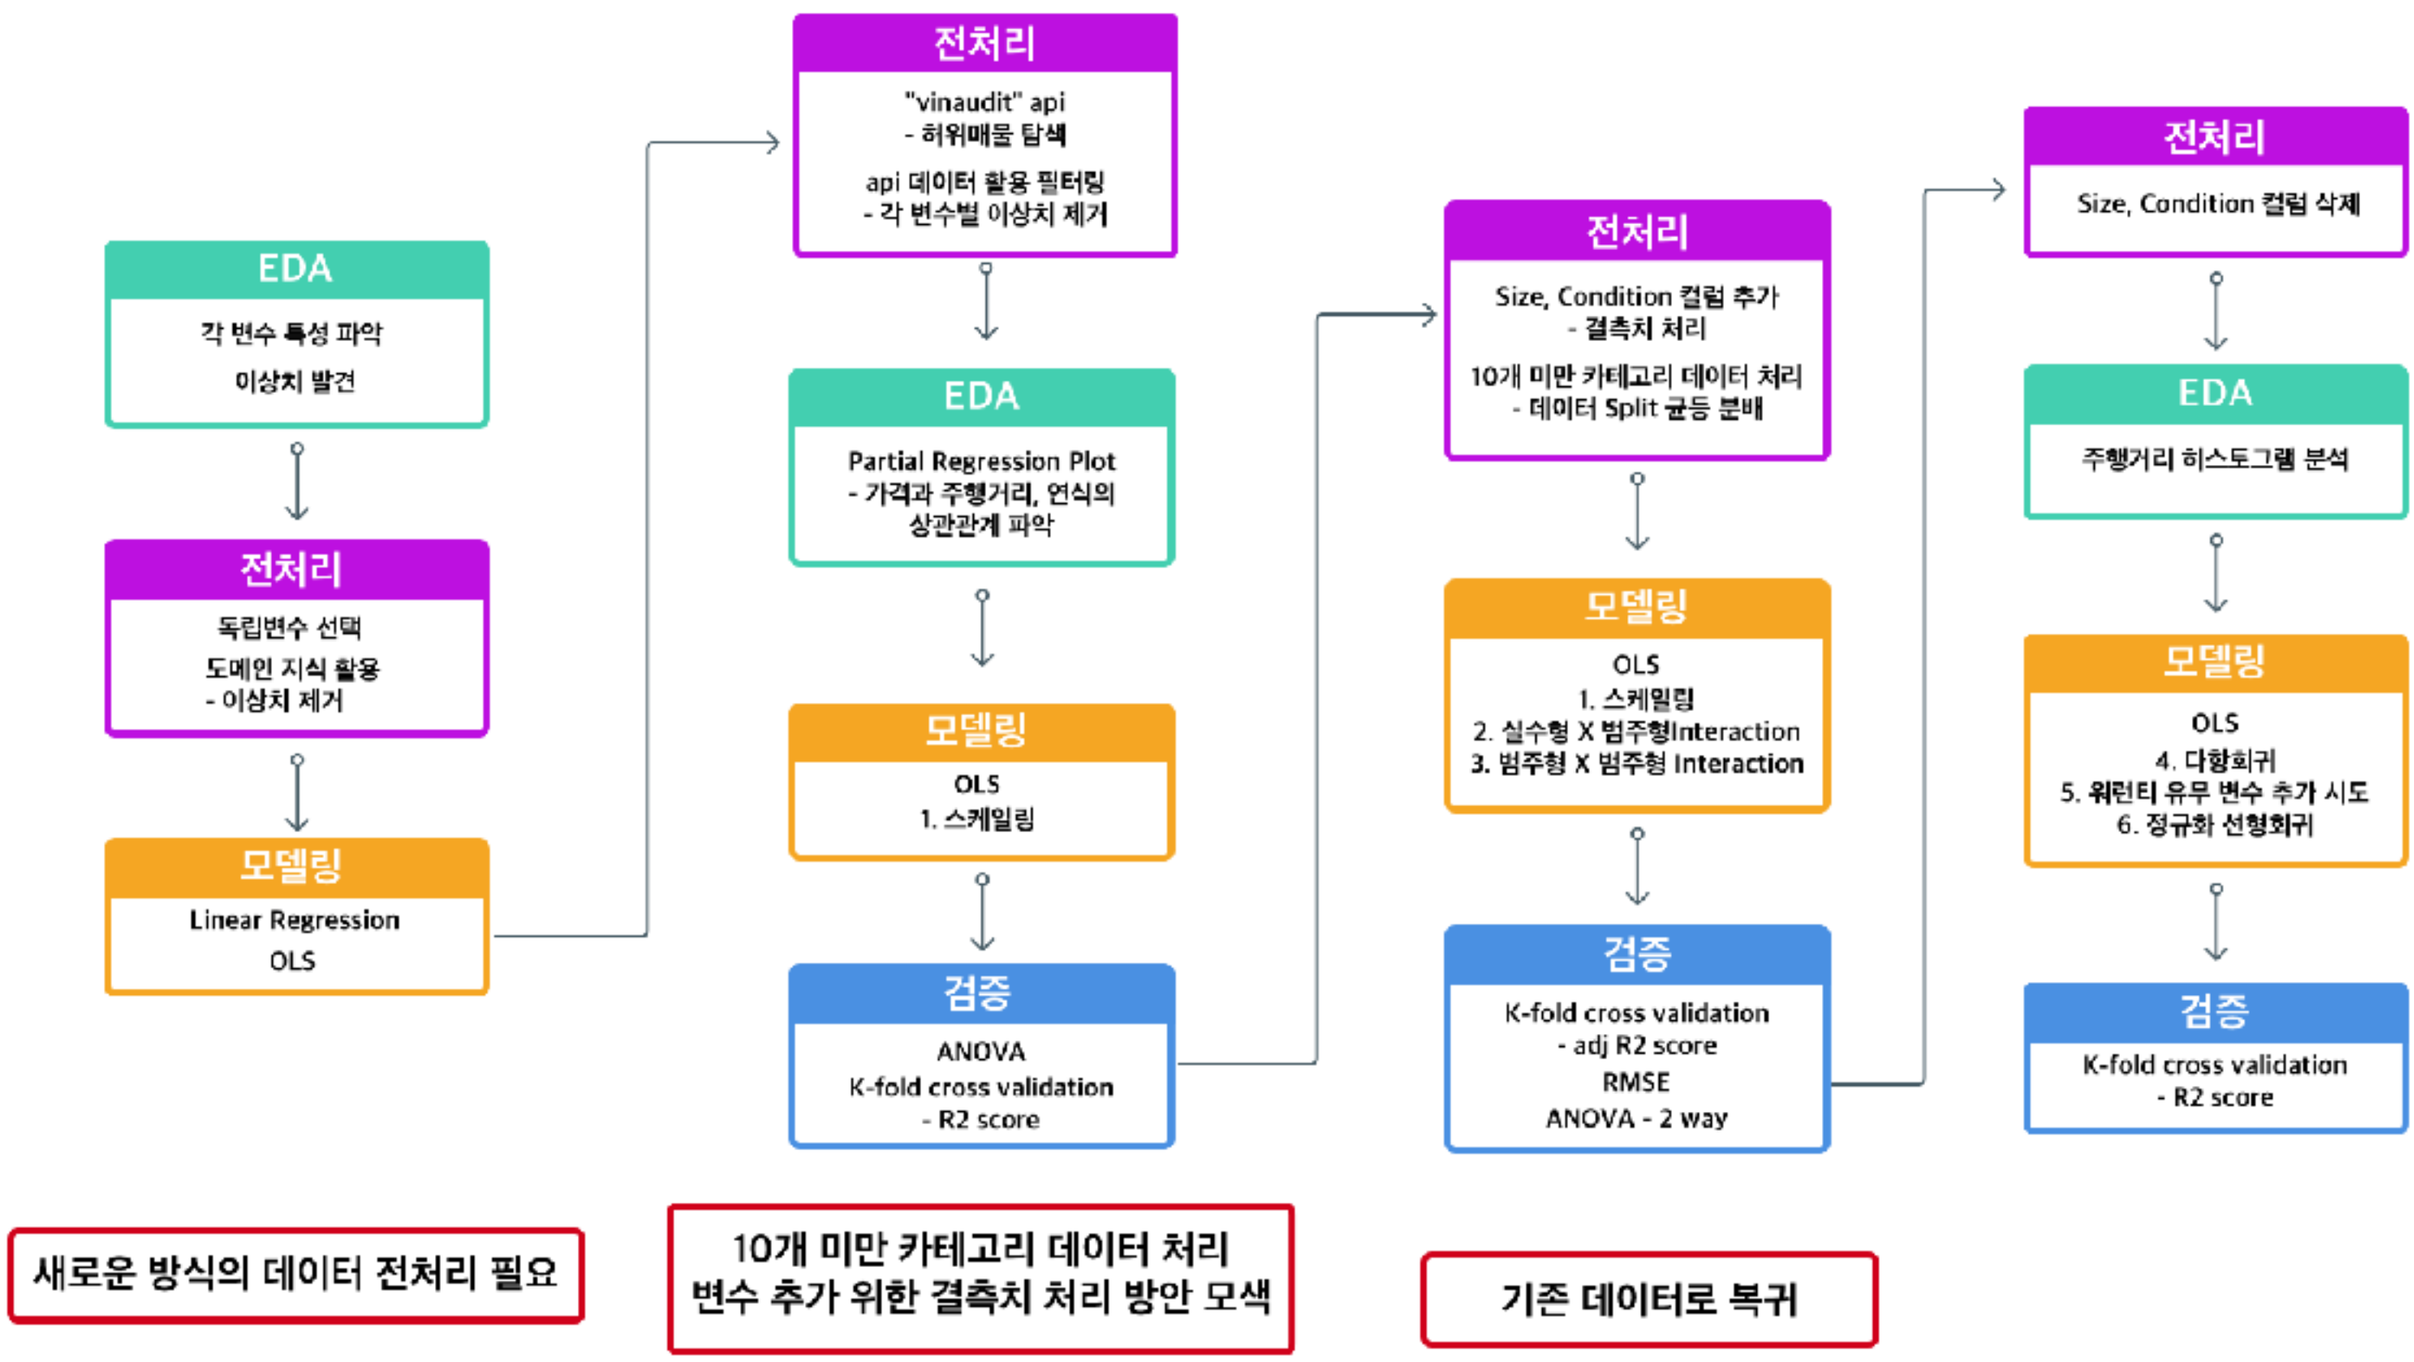

Issue

- 데이터 특성상 허위 및 광고성 매물로 인한 주행거리, 연식등의 이상치들이 다수 존재.
- 예측 모델 성능 향상을 위한 **이상치 탐색 및 제거**가 관건

Issue solving

- vin(차대번호)를 활용한 이상치 탐색 작업 진행
- https://www.vinaudit.com/ 에서 제공하는 api를 이용하여 허위 매물 탐색 및 이력 조회
- 위 api는 미국 정부기관에서 관리하는 데이터베이스를 기반으로 제작, 데이터 신뢰도가 높음

Machine Learning Project

모델링

Model 1 : 종속변수(가격)을 Log 연산, 실수형 독립변수 연식과 주행거리를 정규화 시킨 기본 선형 모델

Model 2 : 실수형 변수와 범주형 변수의 Interaction(상호 작용) formula 추가

연식(year)

- **연도별 인기있는 자동차 제조사가 다르기 때문에,** 연식이 가격예측에 미치는 영향이 제조사에 따라 달라진다.
- **금융위기를 기점으로 소형 SUV등의 점유율이 상승 하는 등**, 연식이 가격예측에 미치는 영향이 **차량 종류**에 따라 달라진다.

주행거리(odometer)

- **장거리 혹은 단거리 운행에 적합한 연료 종류가 다르기 때문에**, 주행거리가 가격 예측에 미치는 영향이 **연료 종류**에 따라 달라진다.
- **장거리 운행에 적합한 특정 실린더 종류가 있기 때문에**, 주행거리가 가격 예측에 미치는 영향이 **실린더 종류**에 따라 달라진다.
- **장거리 운행을 하는 특정 차종이 있기 때문에**, 주행거리가 가격 예측에 미치는 영향이 **차량 종류**에 따라 달라진다.

Model 3 : 범주형변수와 범주형 변수의 interaction 추가

- **제조사별로 가격에 미치는 영향이 실린더 갯수에 따라 달라질 수 있기 때문에, 제조사와 실린더의 interaction은 가격 예측에 영향을 준다.**
- **차종이 가격에 미치는 영향이 구동방식에 따라 달라질 수 있기 때문에, 제조사와 실린더의 interaction 은 가격 예측에 영향을 준다.**

Model 4 : 연식과 주행거리에 다항식추가

- Partial Regression Plot에서 곡선의 그래프를 발견

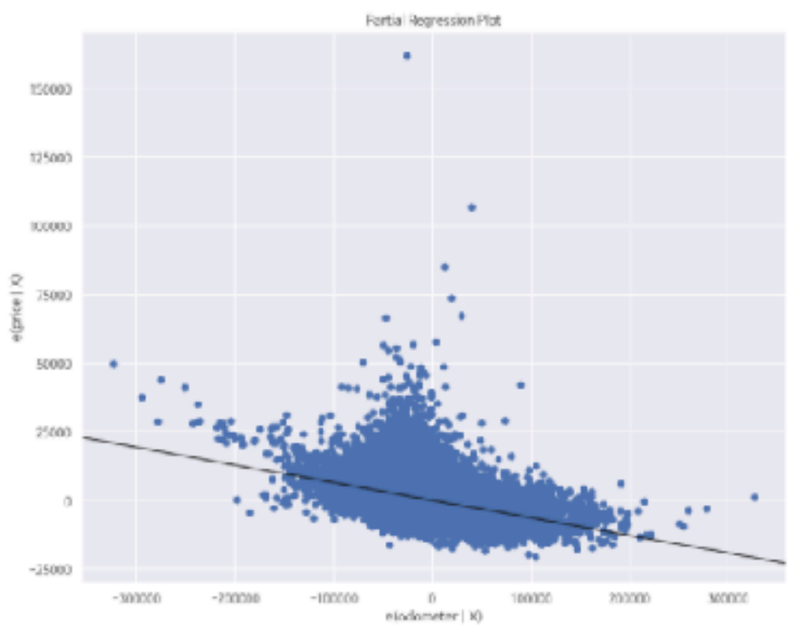

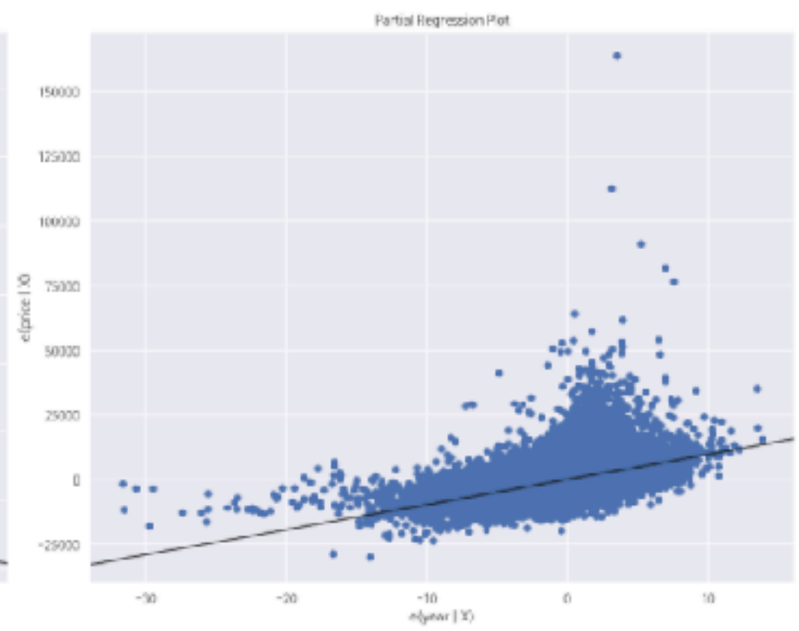

Model 5 : 중고차 보증수리 유무에 관한 데이터를 추가

- 포드, 토요타, 현대 등의 중고차 워런티 서비스 제공 기준 약 6만마일
- 보증수리 유무 카테고리 데이터를 추가 하여 모델링

Model 6 : Ridge, Lasso, Elastic Net을 이용

- 정규화 선형회귀 방법을 이용 선형회귀 계수에 대한 제약 조건을 추가

결과 : Model 4번이 안정적으로 최상의 성능을 보임

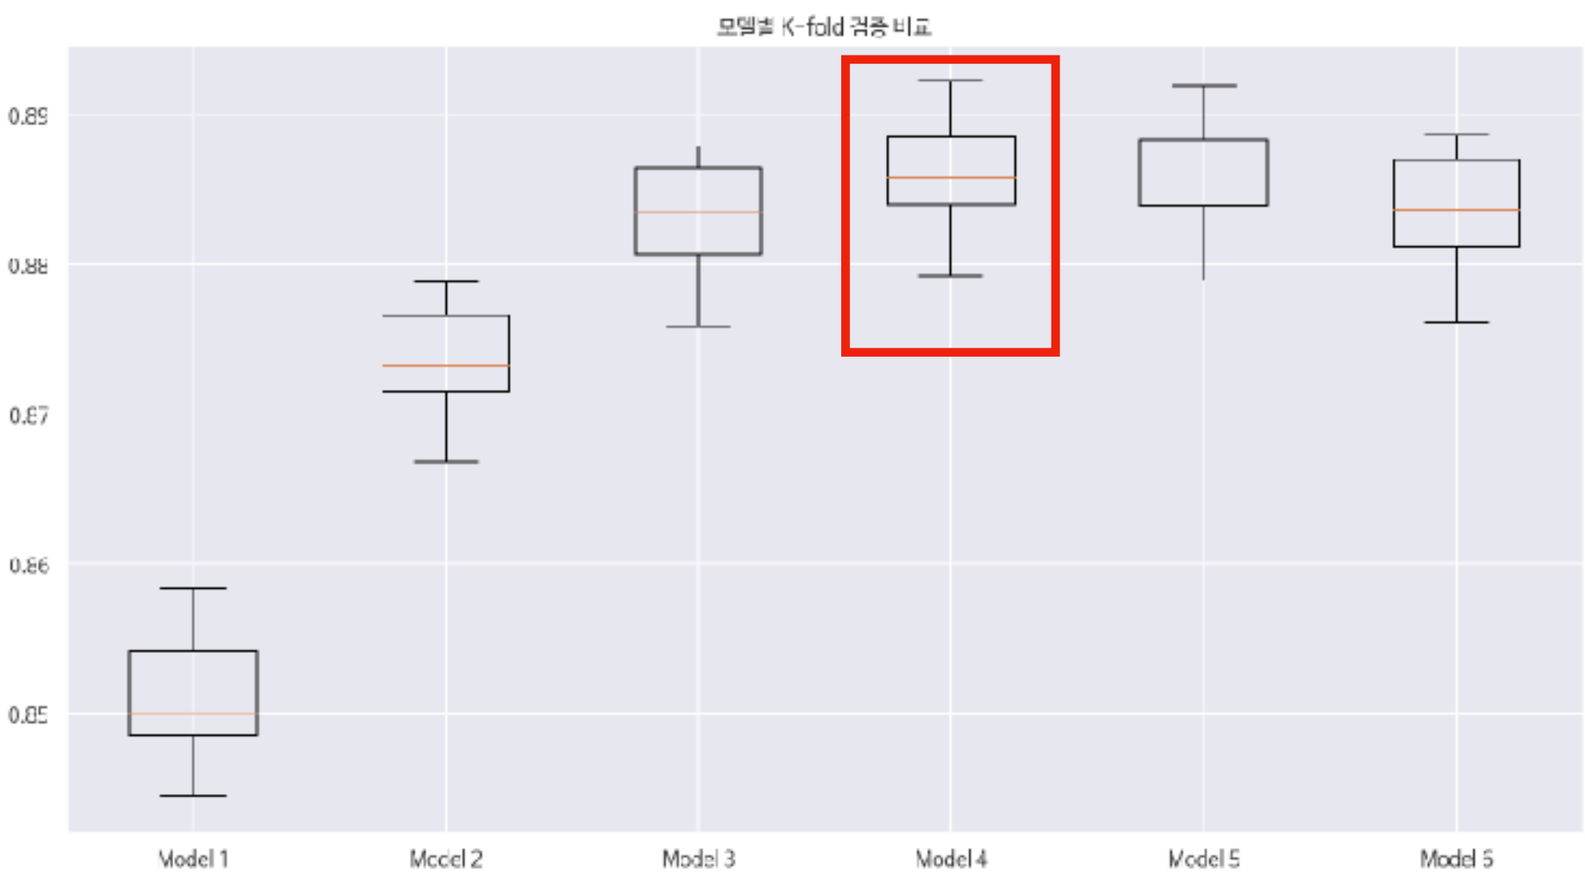

Machine Learning Project

연구 가설 검증

가설 1 : 주행거리 5만km 이하일때 차량을 파는것이 가격적으로 유리할 것이다.

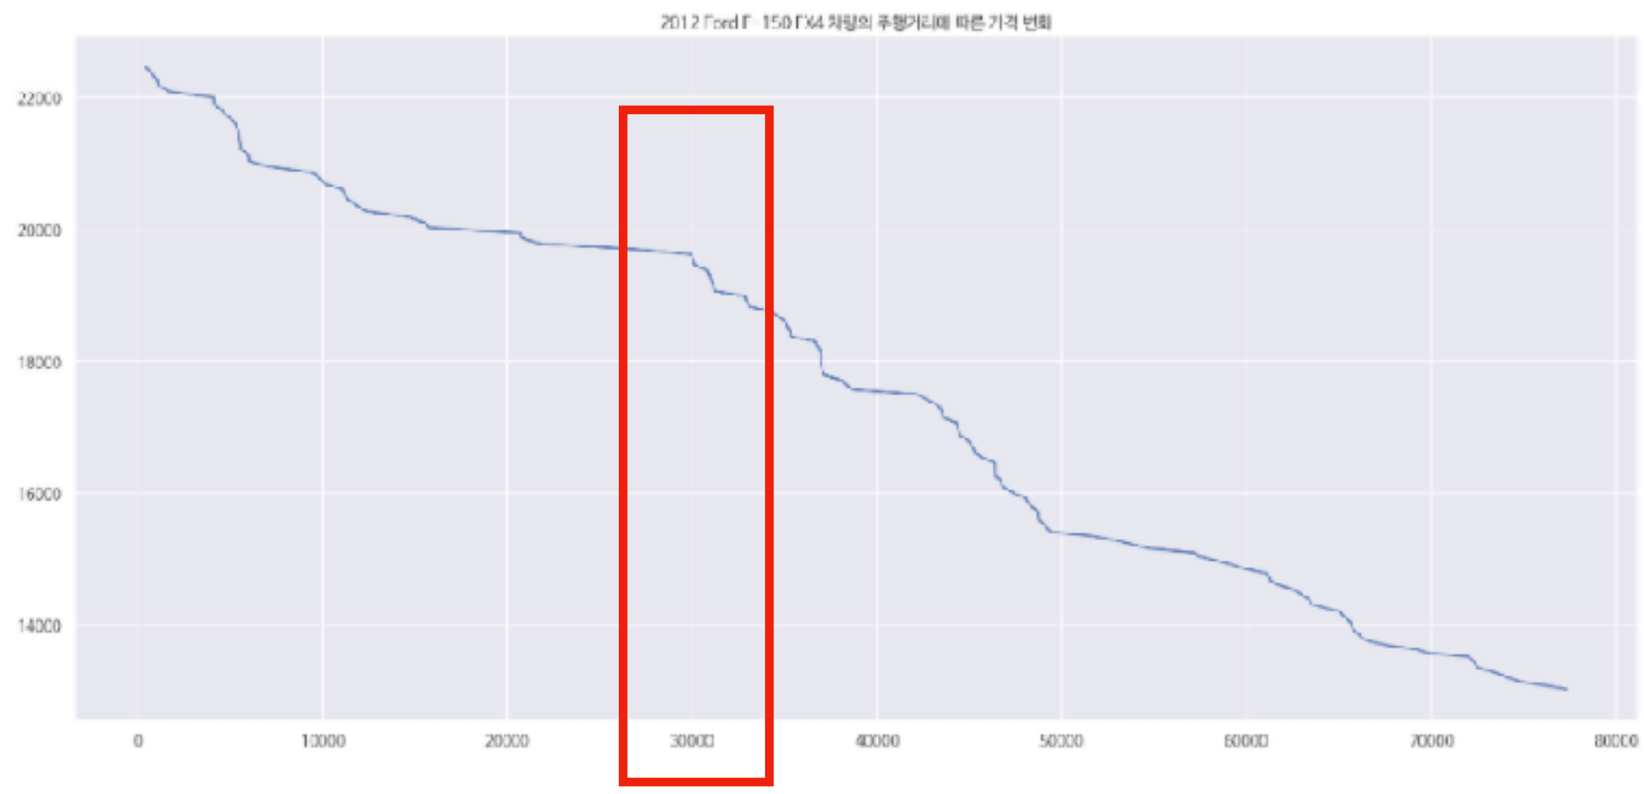

- 데이터에서 가장 높은 빈도를 보이는 2012 Ford F-150 FX4 모델의 가격이 약 3만마일(4만8천km)부터 급격히 떨어짐

가설 2 : 지역별 가격 차이가 있을 것이다.

	sum_sq	df	F	PR(>F)
C(type)	227.0251934	12.0000000	283.6542865	0.0000000
C(manufacturer)	492.5864559	35.0000000	211.0138517	0.0000000
C(transmission)	24.7197262	2.0000000	185.3148419	0.0000000
C(title_status)	27.6030497	5.0000000	82.7720300	0.0000000
C(state)	108.8557151	50.0000000	32.6420761	0.0000000
C(paint_color)	12.9745019	11.0000000	17.6845719	0.0000000
Residual	2974.8001219	44602.0000000	nan	nan

- Anova 독립 검정 결과 State 카테고리 데이터의 F 검정통계량을 확인 할수 있고, 유의확률도 신뢰가능한 수준인것을 확인

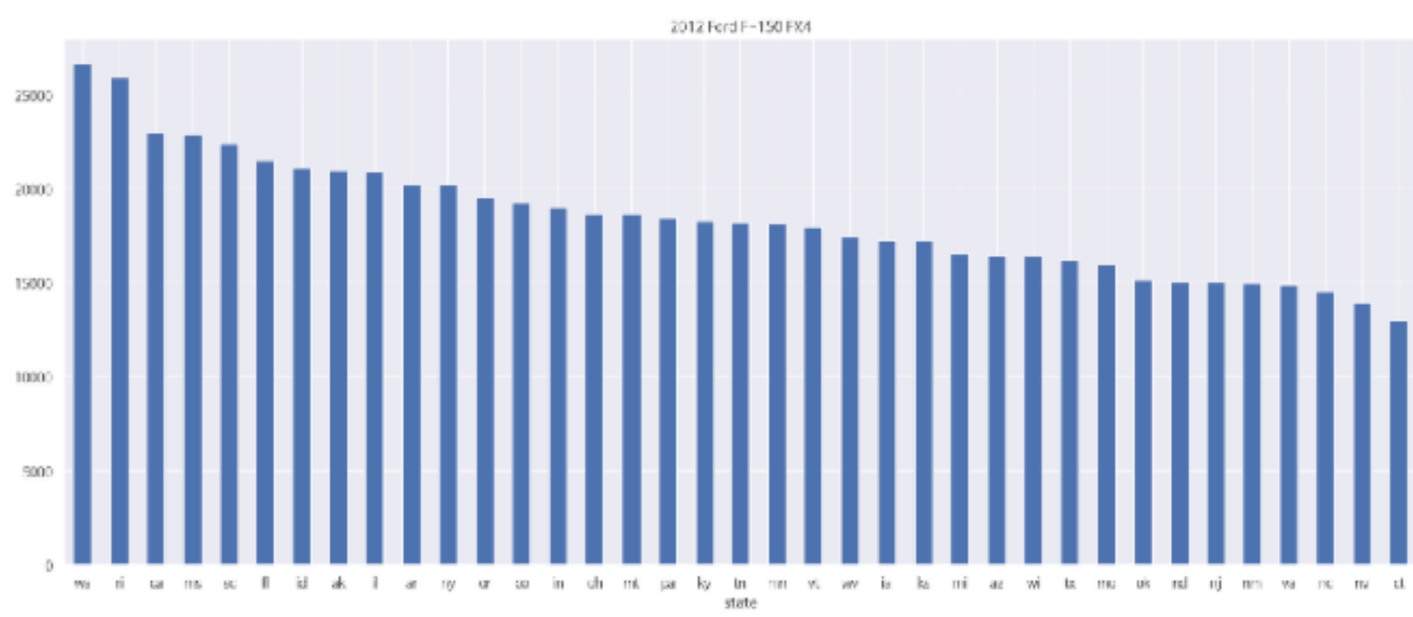

- 실제 데이터 상의 워싱턴 주와 코네티컷 주에서 각각 판매되는 2012 Ford F-150 FX4 모델 가격의 차이는 약 1만불

한계 및 개선점

- 자동차 보증수리 여부에 대한 명확한 데이터의 부재로, Model 5의 아이디어를 좀더 발전 시키지 못함

Notebook : https://nbviewer.jupyter.org/github/HowardHowonYu/usedcar_regression_project/blob/howard/howard/used_car_regression_final.ipynb

Works

Job Hunter 프로젝트

구직 공고 탐색 Slack app 제작

Technical Skills : Python, Scrapy, AWS, Flask, Slack api, MySQL

Goal

- 매일 업데이트 되는 데이터 관련 구직 정보를 획득할수 있는 Slack app 제작

Structure

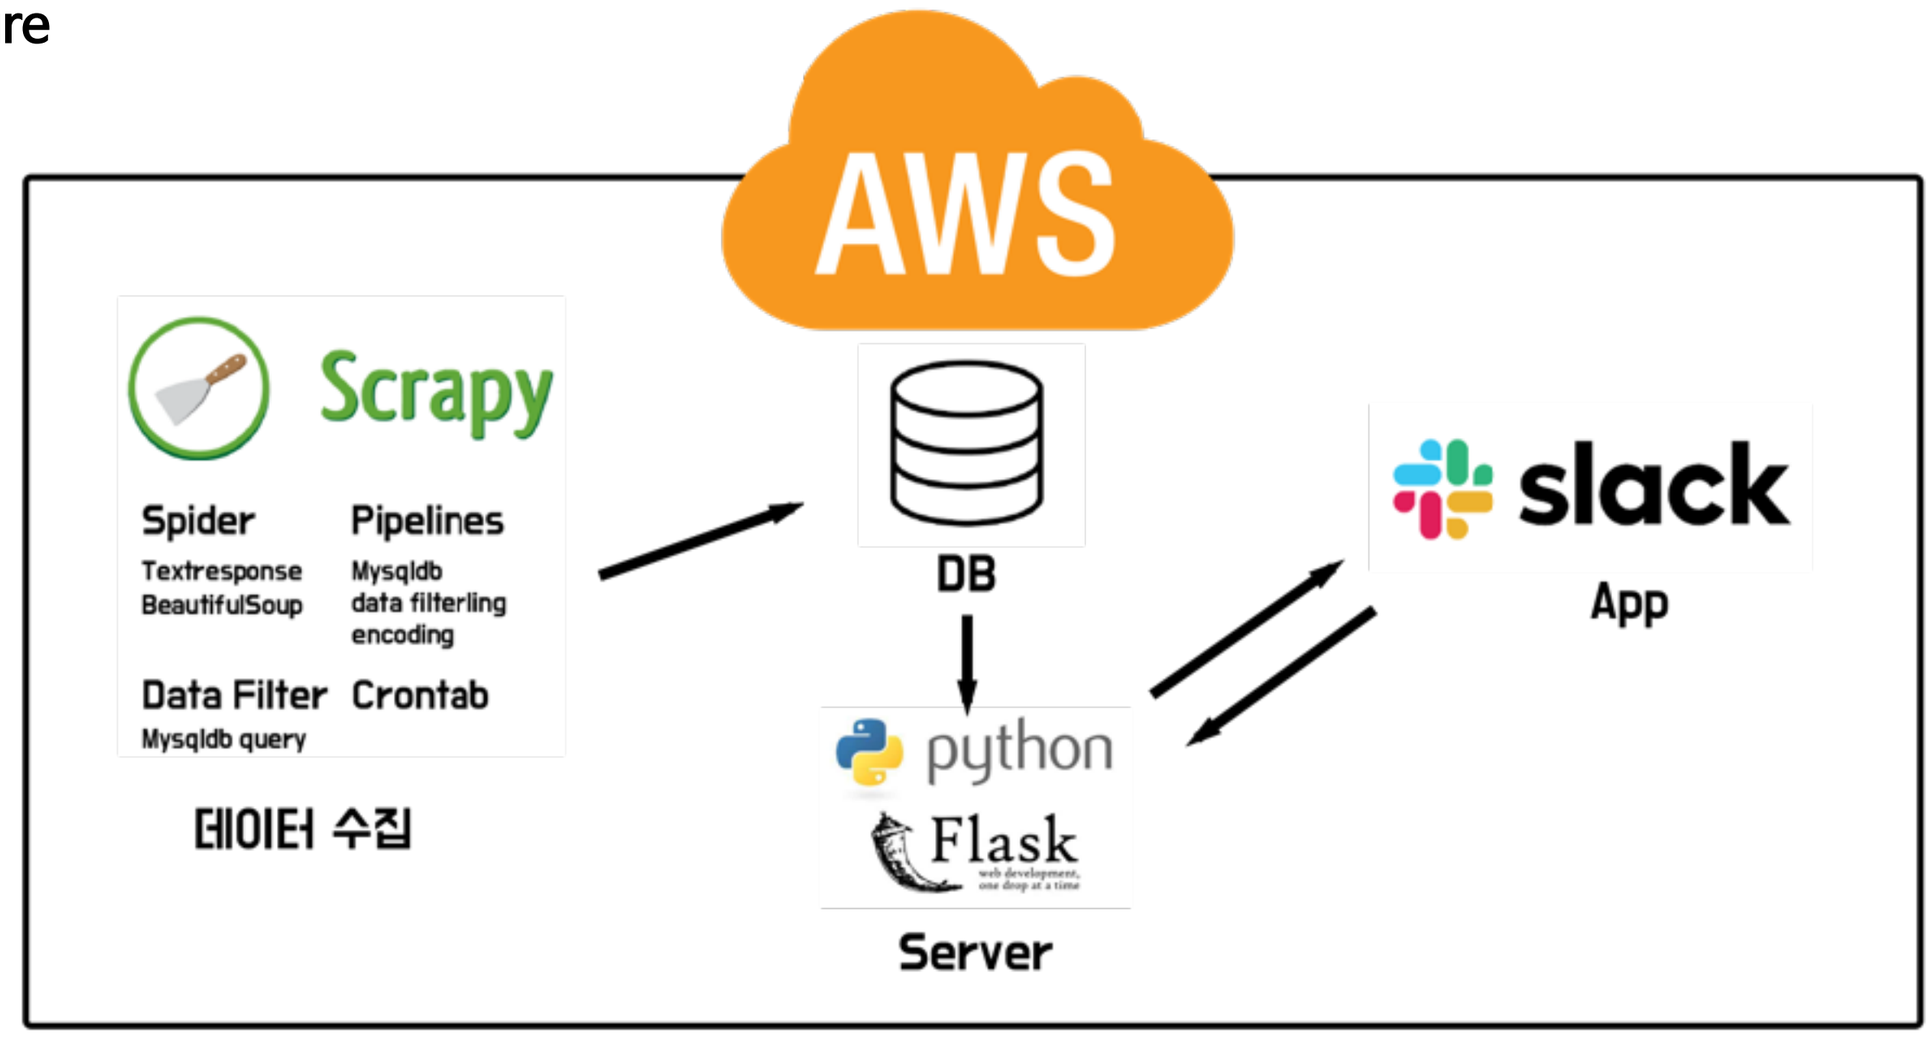

1. **BeautifulSoup**로 HTML로 파싱하여 Css-selector를 활용한 데이터 추출
2. **TextResponse**로 xpath를 활용
3. 구직 공고 사이트별 두가지 방식의 크롤링 코드를 **Scrapy** 프레임워크에 적용
4. **AWS EC2** 에서 **crontab**을 이용해 주기적으로 크롤링 실행, DB에 데이터 저장
5. **Flask**를 이용해 Slack app 제작에 필요한 server 구축

Detail

수집 대상
- 사람인, 잡코리아, 로켓펀치등 구직 사이트

수집 주기
- 매일 새벽 2시 크롤링 진행

수집 데이터
- 회사명, 사업분야, 직무, 공고 링크, 연봉 및 조건, 기한, 직무관련 키워드, 회사(사무실 위치)

DB
- SQL Injection을 방지하기 위한 방법 적용 (SQl ALchemy 등 api방식으로 구현)

Slack app
- 현재 AWS EC2에서 tmux로 Session을 나누어 Flask 실행 중

PROJECTS

Works

Issue

- 로켓펀치는 HTML 전체 코드를 json안의 String 형태로 반환함
- 잡코리아는 요청 횟수에 따라 크롤링을 차단

Issue solving

로켓펀치

- Scrapy Spider 생성자 함수 설정시 json의 String을 추출하고, String데이터를 HTML로 파싱하는 과정 설정

잡코리아

- 에러를 만날때 마다 AWS EC2 서버를 재시작 하는 방식으로 매번 새로운 ip로 접근하는 방식을 고려
- 최적화된 Term을 찾는 방식도 진행

결과

- 현재 패스트캠퍼스 데이터사이언스 스쿨 12기 Slack Workspace에서 Job Hunter app 서비스 중

한계 및 개선점

- 잡코리아의 blcok을 회피하는 더 좋은 방안에 대한 구상 필요
- SQL injection을 피하기 위한 SQL Alchemy등 api방식을 활용할 필요

Machine Learning Project

CNN 이미지 분류

Keras를 활용한 표지판 분류 프로젝트

Technical Skills : Python, Keras, Pandas, Numpy

Notebook : https://nbviewer.jupyter.org/github/HowardHowonYu/traffic-sign-recognition/blob/master/trafic_sign.ipynb

Workflow

Step 1 : "도로교통공단 교통안전표지 일람표"에서 adobe illustrator를 이용 이미지 추출

출처 : https://www.koroad.or.kr/kp_web/safeDataView.do?board_code=DTBBS_030&board_num=100162

Step 2 : Image Augementation 진행

- 각 표지판 이미지를 1000장씩 augementation 진행
- 영상에서 표지판이 인식되는 이미지의 모양을 고려하여, 이미지 왜곡, 회전, 명도등을 설정

Step 3 : CNN 모델링

- Keras로 CNN 구현
- EarlyStopping을 사용해 val_loss를 모니터함. 총 33번의 epoch

Machine Learning Project

Accuracy, Loss

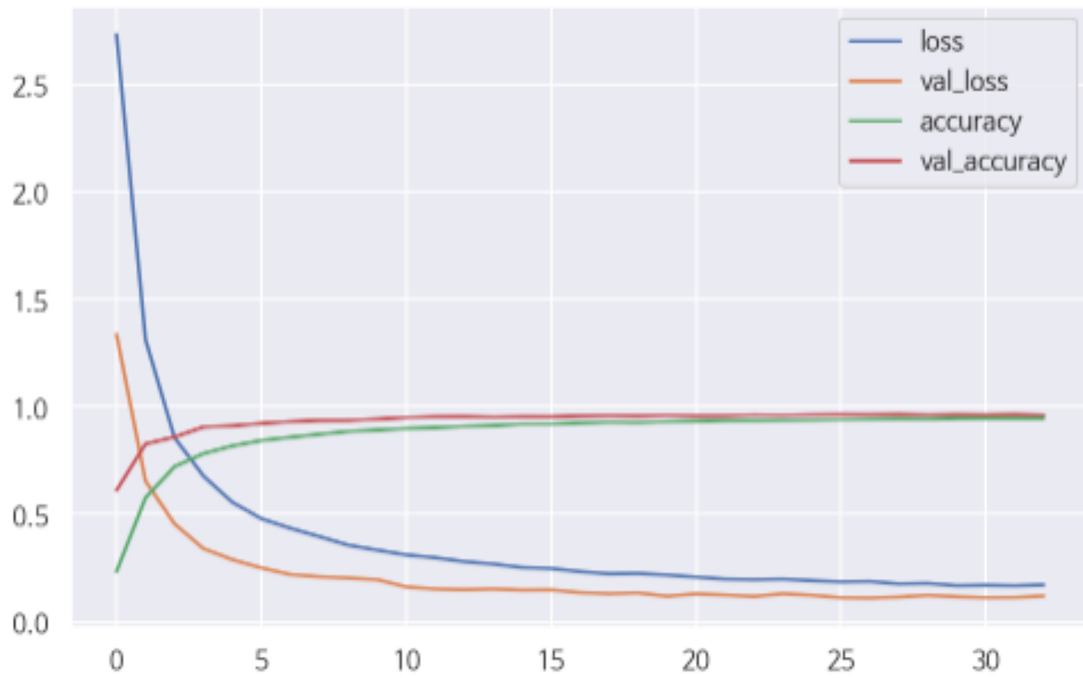


```
model.evaluate(X_test, y_test)
```

executed in 18.9s, finished 16:54:58 2020-06-03

```
17000/17000 [==============================] - 19s 1ms/step

[0.12164360738888567, 0.9624117612838745]
```

- loss값과 validation loss 값이 과적합 없이 수렴하는 것을 확인
- accuracy 역시 비슷한 양상을 보임
- test 데이터에 대한 accuracy 약 0.962

Step 4 : 결과 분석

- 사람의 눈으로 판단하기 힘든 데이터들은 예측해 내지 못함
- 실제 표지판 사진으로 예측

```
result = model.predict(X)
label_to_str[np.argmax(result, axis=1)[0]]
```

executed in 7ms, finished 16:09:25 2020-06-07

'좌우로이중굽은도로'

한계 및 개선점

- Image Augementation의 옵션을 더 조정해 모델 성능 개선이 필요
- 이미지의 수량을 단계적으로 확장시켜 모델 학습
- 모델링(레이어 구성)을 위한 하이퍼 파라미터 조정 필요

Machine Learning Project

카카오 아레나 대회

멜론 플레이리스트 곡 목록 및 태그 예측 – 진행중

Technical Skills : Python, Implict, Pandas, Numpy

Goal

- 플레이리스트의 일부 정보를 가지고, 노래 100곡과 태그 10개를 생성

데이터셋 개요

노래 장르, 곡 별 메타 데이터, Train, Validation, Test 데이터, Mel-spectogram 데이터(약 280G)

Matrix Factorization + Cosine Similarity

노래 100곡은 협업 필터링 방식

$$\text{playlist} \quad \begin{pmatrix} 1&0&0&0&1&0&0&1 \\ 0&0&1&0&0&1&0&0 \\ 1&0&1&0&0&0&1&1 \\ 0&1&0&0&0&1&0&0 \\ 0&0&1&0&0&1&0&0 \\ 1&0&0&0&1&0&0&1 \end{pmatrix} \approx \underbrace{\begin{pmatrix} \quad X \quad \end{pmatrix}}_{f} \begin{pmatrix} \quad Y \quad \end{pmatrix} \}f$$

songs + tags

implicit의 AlternatingLeastSquares를 활용해 추천시스템 구축

태그 10개는 Cosine Similarity 를 활용

$$magnitude = \sqrt{(x^2 + y^2 + z^2 + \ldots)}$$

$$vector = \left(\frac{x}{magnitude}, \frac{y}{magnitude}, \frac{z}{magnitude}, \ldots \right)$$

가중치 계산

playlist 벡터 계산

Playlist x Tags 행렬의 값은 0과1이 아닌, 0~1사이의 실수값을 가지게 됨
이후 cosine similarity matrix를 이용해 Tag 예측

결과

용산꿀주먹 (My team)		**0.048762**	0.007099 (93)	0.284849 (16)	11

Song 예측 순위 93위(93/101)
Tag 예측 순위 16위 (16/101)
현재 대회 진행중

한계 및 개선점

- ALS 모델 추가 개선
- Mel-spectogram 데이터를 활용한 노래 Classification 작업 진행
- Autoencoder를 활용한 모델링